

Analisi Strategie di Risparmio per Wonder S.P.A.



Ferrari Federico Palladino Mirko



Corso di Big Data Analytics & Data Engineering
ITSInCom
Busto Arsizio, Italia
Anno Accademico 2024 - 2025

Tabella dei contenuti

Introduzione al Progetto	2
Contesto del Progetto	2
Problema da Risolvere	2
Organizzazione del Gruppo di Lavoro	3
Data Engineering	4
Data Loading	4
Data Cleaning	6
TELEMETRY_CHANGES	7
LOTTIPR	9
MATPRIME	9
MACCHINE	10
DETGRMAC	11
RESQUANT	11
RESTURNI	12
RESTEMPI	14
Data Warehousing	15
Data Visualization	17
Machine Learning	19
Descrizione del Modello	19
Analisi delle Prestazioni	19
Conclusioni	22
UML	23
Modello Socio-Tecnico	23

Introduzione al Progetto

Contesto del Progetto

L'azienda Tesar S.P.A. ha riconosciuto la necessità di ottimizzare il processo di monitoraggio dell'attività aziendale di Wonder S.P.A. al fine di identificare inefficienze e aree di miglioramento per ridurre i costi operativi e aumentare l'efficienza complessiva.

Il progetto prevede lo sviluppo di modelli analitici avanzati per fornire al cliente Wonder un supporto decisionale efficace e un quadro dettagliato delle prestazioni aziendali dal 10/09/2018 al 11/02/2024.

Problema da Risolvere

L'obiettivo di Tesar è sviluppare un sistema analitico che, basandosi sui dati di produzione e telemetria forniti da Wonder, possa identificare opportunità di risparmio e ottimizzazione delle operazioni.

Il team di analisti dati di Tesar deve condurre un'analisi dettagliata dei dati storici, utilizzando tecniche statistiche e algoritmi di Machine Learning al fine di identificare pattern e trend significativi relativi alla produzione, alla gestione degli scarti, all'efficienza delle macchine e ad altri parametri critici per l'attività aziendale. I risultati devono essere presentati tramite un report interattivo, offrendo al cliente Wonder una panoramica completa delle potenziali aree di miglioramento e delle azioni consigliate per ottimizzare le performance aziendali.

Organizzazione del Gruppo di Lavoro

Le competenze necessarie per affrontare la problematica descritta nel paragrafo precedente comprendono conoscenze approfondite in Data Engineering, Database Management, Data Analysis, Data Visualization e Machine Learning.

Dopo aver svolto un'accurata analisi dei requisiti necessari e pianificato le attività da svolgere, abbiamo immediatamente provveduto ad organizzare il nostro gruppo in modo da massimizzare la collaborazione e la produttività. Abbiamo definito così i ruoli di ogni membro del team e le relative scadenze da rispettare.

Il nostro team ha disposto di una suite di software volti a compiere operazioni di analisi, tra cui: SQL Server Management Studio per l'esecuzione di query SQL, Visual Studio per l'esecuzione di script Python e per svolgere attività di AutoML, GitHub e Google Documents per la stesura della documentazione, Power BI per lo sviluppo di un report interattivo e Microsoft Teams per le comunicazioni interne.

Data Engineering

Data Loading

Il processo iniziale di data loading ha avuto inizio il 21/02/2024 quando è stato fornito l'accesso al database "TS_WND" sotto forma di file BAK. Considerando le dimensioni significative di questo file, pari a 27.5 GB, e la necessità del team di analisti di lavorare simultaneamente su di esso, si è optato per l'utilizzo di una macchina virtuale (VM) dotata di SQL Server Management Studio (SSMS) e di sufficiente spazio sul disco.

Questo approccio prevede il ripristino del database in locale sulla VM, al fine di consentire l'accesso remoto al database On-Premise della VM. Per configurare l'accesso remoto al database, è stata seguita la seguente procedura:

- 1. Accedere a SSMS sulla VM a stabilire una connessione con il localhost;
- 2. Navigare fino a Server > Properties > Security e, sotto "Server authentication", selezionare "SQL Server and Windows Authentication mode";
- 3. Navigare fino a Server > Properties > Connections e, sotto "Remote server connections", selezionare "Allow remote connections to this server";
- 4. Creare un'utenza per ciascun membro del team;
- 5. Accedere a SQL Server Configuration Manager sulla VM e navigare fino a SQL Server Network Configuration > Protocols for MSSQLSERVER. Qui, abilitare "TCP/IP" facendo click con il tasto destro del mouse e selezionando "Enable":

- 6. Navigare fino a SQL Server Services. Qui, riavviare "SQL Server (MSSQLSERVER)" facendo click con il tasto destro del mouse e selezionando "Restart";
- 7. Accedere a Windows Firewall with Advanced Security sulla VM e navigare fino a Inbound Rules per selezionare nel pannello di destra "New Rule..." e aprire così il New Inbound Rule Wizard;
- 8. Nel New Inbound Rule Wizard, sotto "Rule Type", selezionare "Port";
- 9. Di seguito, sotto "Protocol and Ports", selezionare "TCP" e "Specific local ports" impostando come numero di porta 1433;
- 10. Di seguito, sotto "Action", selezionare "Allow the connection";
- 11. Di seguito, sotto "Profile", assicurarsi che solo "Domain" sia selezionato;
- 12. Di seguito, sotto "Name", impostare un nome per la nuova Inbound Rule del firewall;
- 13. Per infine eseguire l'accesso remoto al database basta considerare la VM come un server: su SSMS, utilizzare l'IP della VM come "Server name" e selezionare "SQL Server Authentication" come metodo di autenticazione per accedere con le credenziali delle utenze create nel punto 4.

Data Cleaning

La fase di data cleaning rappresenta un passaggio cruciale per garantire l'integrità e la qualità dei dati analizzati. Questa fase è iniziata con un'attenta esaminazione di ciascuna delle 1313 tabelle contenute nel database, al fine di individuare dati dai quali trarre informazioni significative e risolvere eventuali problemi di inconsistenza, incompletezza o incoerenza.

Di seguito sono elencate le tabelle selezionate per la loro pertinenza con l'analisi condotta insieme al motivo di tale scelta:

Tabella	Scopo
TELEMETRY_CHANGES	Creare la tabella dei fatti facts_telemetry
LOTTIPR	Creare la tabella dimensionale DIM_LOTTIPR
MATPRIME	Creare la tabella dimensionale Dim_matprime
MACCHINE	Creare la tabella dimensionale Dim_macchine
DETGRMAC	Creare la tabella dimensionale Dim_grumacc
RESQUANT	Creare la tabella dimensionale Dim_prod
RESTURNI	Creare la tabella dimensionale DIM_FERM
RESTEMPI	Creare la tabella dimensionale DIM_RESA
CICLI	Sostituire il campo FASE col campo DESLAV per avere un

	nome al posto di un codice e ottenere il CICLOTEO (CICLO TEOrico) delle macchine
ARTICOLI	Sostituire il campo CODART col campo DESART per avere un nome al posto di un codice
TABREP	Sostituire il campo CODREP col campo DESREP per avere un nome al posto di un codice
TABCSCAR	Sostituire il campo CODCDS col campo DESCDS per avere un nome al posto di un codice
TABCFER	Sostituire il campo CODFERM col campo DESFERM per avere un nome al posto di un codice
DISTBASE	Sostituire il campo CODMATP col campo DESMATP per avere un nome al posto di un codice

Queste tabelle sono soggette a una serie di trasformazioni al fine di adattarle agli obiettivi dell'analisi. Tali trasformazioni sono descritte nel dettaglio nelle sezioni seguenti.

TELEMETRY_CHANGES

La tabella TELEMETRY_CHANGES contiene i dati di telemetria provenienti dai sensori lloT (Industrial IoT) posti sulle macchine. È importante notare che le transazioni, le trasmissioni dati tra macchina e database, avvengono solo in seguito a cambiamenti nei valori di telemetria, al fine di ottimizzare il quantitativo di dati raccolti. Questo approccio mira a ridurre la dimensione complessiva dei dati senza compromettere la loro rilevanza per operazioni di analisi.

I campi considerati durante il processo di data cleaning per la tabella TELEMETRY_CHANGES includono:

Campo	Data Type	Descrizione e uso
PATAMETER_NAME	VARCHAR(50)	Il nome della telemetria
PARAMETER_VALUE	VARCHAR(50)	Il valore della telemetria
READING_TIMESTAMP	DATETIME	Data e ora di lettura delle telemetrie
TRANSACTION_ID	VARCHAR(100)	Identifica le transazioni, le trasmissioni dati tra macchina e database
DATASTATE	CHAR(20)	Lo stato della connessione al momento della transazione
LOTTOPR	VARCHAR(10)	(LOTTO di PRoduzione) Identifica il lotto di produzione
FASE	VARCHAR(3)	Identifica l'operazione eseguita dalla macchina al momento della transazione
CODART	VARCHAR(30)	(CODice ARTicolo) Identifica l'articolo in produzione
MACC	VARCHAR(15)	(MACChina) Identifica la macchina
OPERAT	VARCHAR(4)	(OPERATore) Identifica l'operatore

^{*}Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella TELEMETRY_CHANGES è usata come base per la creazione della tabella facts_telemetry, come descritto nel seguente <u>link</u>.

LOTTIPR

La tabella LOTTIPR contiene dati fondamentali relativi ai lotti di produzione, che rappresentano gli ordini inviati alle macchine per la produzione di determinati articoli. Questi dati forniscono informazioni cruciali sui tempi di produzione, le quantità prodotte e gli articoli coinvolti nei processi di produzione.

I campi considerati durante il processo di data cleaning per la tabella LOTTIPR includono:

Campo	Data Type	Descrizione e uso
LOTTOPR	VARCHAR(10)	(LOTTO di PRoduzione) Identifica il lotto di produzione
CODART	VARCHAR(30)	(CODice ARTicolo) Identifica l'articolo in produzione
SCADENZA	DATETIME	Data di consegna del lotto
DATINIPRO	DATETIME	(DATa di INIzio PROduzione) Data e ora di inizio produzione del lotto
DATFINPRO	DATETIME	(DATa di FINe PROduzione) Data e ora di fine produzione del lotto

^{*}Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella LOTTIPR è usata come base per la creazione della tabella DIM_LOTTIPR, come descritto nel seguente <u>link</u>.

MATPRIME

La tabella MATPRIME funge da anagrafica per le materie prime adoperate nei processi produttivi. Tuttavia, per ottenere informazioni più dettagliate sui lotti in cui queste materie prime sono impiegate, si può fare riferimento alla tabella DISTBASE. La tabella DISTBASE fornisce informazioni sui lotti di produzione associati alle materie prime. Questa relazione tra MATPRIME e DISTBASE è essenziale per comprendere completamente l'utilizzo delle materie prime nel contesto di produzione.

I campi considerati durante il processo di data cleaning per la tabella MATPRIME includono:

Campo	Data Type	Descrizione e uso
CODMATP	CHAR(30)	(CODice MATeria Prima) Identifica la materia prima
DESMATP	CHAR(40)	(DEScrizione MATeria Prima) Descrive la materia prima

^{*}Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella MATPRIME è usata come base per la creazione della tabella Dim_matprime, come descritto nel seguente <u>link</u>.

MACCHINE

La tabella MACCHINE contiene i dettagli anagrafici delle macchine presenti in azienda. Questi dati sono fondamentali per comprendere la configurazione del parco macchine.

I campi considerati durante il processo di data cleaning per la tabella MACCHINE includono:

Campo	Data Type	Descrizione e uso
MACC	VARCHAR(15)	(MACChina) Identifica la macchina
DESMACC	CHAR(40)	(DEScrizione MACChina) Descrive la macchina
CODREP	CHAR(2)	(CODice REParto) Identifica il reparto dove si trova la macchina

*Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella MACCHINE è usata come base per la creazione della tabella Dim_macchine, come descritto nel seguente <u>link</u>.

DETGRMAC

La tabella DETGRMAC abbina ogni macchina presente in azienda al corrispettivo gruppo macchina. Questi dati sono fondamentali per comprendere la configurazione del parco macchine.

I campi considerati durante il processo di data cleaning per la tabella DETGRMAC includono:

Campo	Data Type	Descrizione e uso
MACC	VARCHAR(15)	(MACChina) Identifica la macchina
GRUMACC	CHAR(15)	(GRUppo MACChina) Descrive la macchina

^{*}Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella DETGRMAC è usata come base per la creazione della tabella Dim_grumacc, come descritto nel seguente <u>link</u>.

RESQUANT

La tabella RESQUANT contiene i dati relativi alle quantità prodotte e scartate di ogni lotto. Questi dati forniscono una panoramica chiara dell'efficienza produttiva dei lotti e delle macchine coinvolte nei processi produttive. Fornendo un utile strumento per valutare le performance produttive e individuare eventuali aree di miglioramento.

I campi considerati durante il processo di data cleaning per la tabella RESQUANT includono:

Campo	Data Type	Descrizione e uso
LOTTOPR	VARCHAR(10)	(LOTTO di PRoduzione) Identifica il lotto di produzione
DATA	DATETIME	Data di produzione
QUANT	FLOAT	(QUANTità) Quantità prodotta o scartata a seconda di CODCDS
CODCDS	CHAR(4)	(CODice Causale Di Scarto) Identifica la causale di scarto

^{*}Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella RESQUANT è usata come base per la creazione della tabella Dim_prod, come descritto nel seguente <u>link</u>.

RESTURNI

La tabella RESTURNI contiene i dati relativi alle fermate avvenute alle macchine. Questi dati sono essenziali per comprendere i motivi delle interruzioni nel processo produttivo e identificare eventuali pattern o anomalie che potrebbero influenzare le prestazioni complessive del sistema.

I campi considerati durante il processo di data cleaning per la tabella RESTURNI includono:

Campo	Data Type	Descrizione e uso
MACC	BIGINT	(MACChina) Identifica la macchina
LOTTOPR	VARCHAR(10)	(LOTTO di PRoduzione) Identifica il lotto di produzione
FASE	VARCHAR(3)	Identifica l'operazione

		eseguita dalla macchina al momento della transazione
OPERAT	VARCHAR(4)	(OPERATore) Identifica l'operatore
TMACC	FLOAT	(Tempo MACChina) Il tempo in cui la macchina era in esecuzione
TLOT	FLOAT	(Tempo LOTto) Il tempo che la macchina ha dedicato al lotto
TOPER	FLOAT	(Tempo OPERatore) Il tempo in cui l'operatore è stato presente
QPROD	FLOAT	(Quantità PRODotta) Quantità prodotta
QSCPR	FLOAT	(Quantità di SCarto di PRoduzione) Quantità di scarto di produzione
QSCLA	FLOAT	(Quantità di SCarto LAvorato) Quantità di scarto lavorato
DATA	DATETIME	Data della fermata
INI	CHAR(4)	(INIzio) Ora di inizio della fermata
FIN	CHAR(4)	(FINe) Ora di fine della fermata
CODFERM *Ogni campo non monzionato r	CHAR(2)	(CODice FERMata) Identifica la fermata registrata

^{*}Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella RESTURNI è usata come base per la creazione della tabella DIM_FERM, come descritto nel seguente <u>link</u>.

RESTEMPI

La tabella RESTEMPI contiene i dati relativi alle fermate avvenute alle macchine, ma al contrario di RESTURNI non presenta la segmentazione in minuti. Questi dati sono necessari per il calcolo della resa produttiva delle macchine, calcolata come $\frac{Ciclo\ teorico}{Ciclo\ reale}$, dove il ciclo teorico è preso dalla

tabella CICLI mentre il ciclo reale viene calcolato con i campi TLOT, QPROD, QSCPR e QSCLA di RESTEMPI tramite la formula

$$\frac{TLOT}{QPROD + QSCPR + QSCLA}$$

I campi considerati durante il processo di data cleaning per la tabella RESTEMPI includono:

Campo	Data Type	Descrizione e uso
LOTTOPR	VARCHAR(10)	(LOTTO di PRoduzione) Identifica il lotto di produzione
MACC	BIGINT	(MACChina) Identifica la macchina
FASE	VARCHAR(3)	Identifica l'operazione eseguita dalla macchina al momento della transazione
CODART	VARCHAR(30)	(CODice ARTicolo) Identifica l'articolo in produzione
TLOT	FLOAT	(Tempo LOTto) Il tempo che la macchina ha dedicato al lotto
QPROD	FLOAT	(Quantità PRODotta) Quantità prodotta
QSCPR	FLOAT	(Quantità di SCarto di PRoduzione) Quantità di scarto di

		produzione
QSCLA	FLOAT	(Quantità di SCarto LAvorato) Quantità di scarto lavorato
CODFERM	CHAR(2)	(CODice FERMata) Identifica la fermata registrata

^{*}Ogni campo non menzionato non è stato rilevante per l'analisi finale.

La tabella RESTEMPI è usata come base per la creazione della tabella DIM_RESA, come descritto nel seguente <u>link</u>.

Data Warehousing

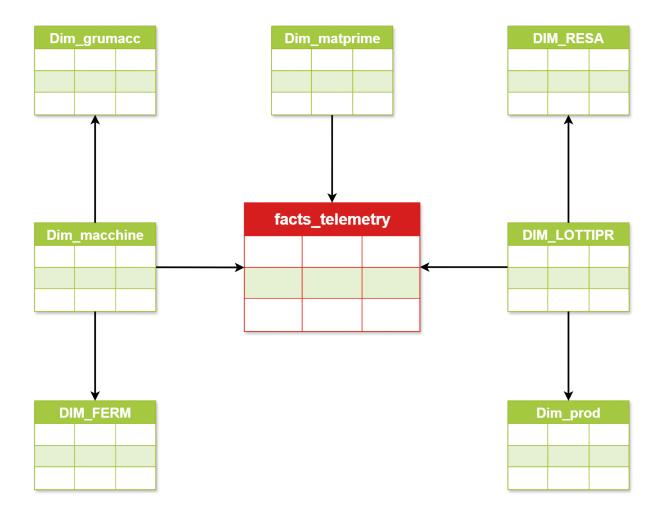
La Data Warehouse (DWH) è stata progettata con l'obiettivo di estrarre informazioni rilevanti per lo sviluppo di strategie mirate al risparmio. La logica alla base dell'approccio seguito consiste nell'integrare all'interno dell'analisi le componenti e le caratteristiche che contribuiscono a definire il processo produttivo, quali gli scarti, i ritardi nella produzione, le fermate delle macchine, l'utilizzo delle materie prime e i dati di telemetria provenienti dalle macchine.

La DWH è strutturata in una tabella dei fatti e sette tabelle dimensionali in uno snowflake schema descritto di seguito.

Tabella	Descrizione
facts_telemetry	È la tabella dei fatti. Contiene i dati di telemetria provenienti dai sensori lloT posti sulle macchine
DIM_LOTTIPR	Contiene i dati relativi ai lotti di produzione, ovvero gli ordini inviati alle macchine per la produzione di

	determinati articoli
Dim_macchine	Contiene i dettagli anagrafici delle macchine presenti in azienda
Dim_grumacc	Identifica i gruppi macchina
Dim_matprime	Contiene i dati anagrafici delle materie prime adoperate nei processi produttivi
Dim_prod	Contiene i dati relativi alle quantità prodotte e scartate di ogni lotto
DIM_FERM	Contiene i dati relativi alle fermate avvenute alle macchine
DIM_RESA	Contiene la resa produttiva delle macchine per lotto e fase (DESLAV)

Il modello dati descritto può essere visualizzato tramite il seguente diagramma.



Data Visualization

Per la parte di visualizzazione dei dati il team si è affidato a Power BI. Il report prodotto è stato progettato per essere non solo uno strumento per svolgere l'analisi e giungere a delle conclusioni, ma anche un mezzo per aiutare l'azienda a monitorare le proprie performance e intervenire prontamente in caso di anomalie. L'analisi si è articolata in due sezioni principali: la prima mirava a individuare soluzioni per ridurre i costi aziendali, mentre la seconda si concentrava sull'analisi degli scarti per identificare correlazioni con altri fattori al fine di fornire strategie utili alla riduzione dei prodotti scartati.



Il report è stato sviluppato considerando i numerosi feedback e le richieste specifiche dell'azienda, al fine di fornire uno strumento completo e user-friendly. La struttura del report includeva un menù per navigare tra le varie dashboard, una barra in alto con il titolo e i filtri principali, e una dashboard centrale ricca di funzionalità. Per migliorare la visualizzazione dei dati, è stato aggiunto uno zoom slider in molti grafici, consentendo di isolare facilmente dati anomali e analizzare con maggiore precisione le tendenze irregolari e i risultati non abituali. Questi elementi interattivi sono stati progettati per facilitare l'analisi dettagliata e aiutare gli utenti a ottenere rapidamente le informazioni necessarie. Queste caratteristiche rendevano il report molto versatile e adattabile alle diverse esigenze analitiche dell'azienda.

Le dashboard del report coprivano diverse aree chiave del processo produttivo. Per le telemetrie, abbiamo creato una dashboard con tre grafici principali, filtri, card e un menù per approfondire ulteriormente l'analisi. Le fermate erano rappresentate con una dashboard che includeva un grafico di andamento, una tabella multi-card e vari filtri. Inoltre, la dashboard dei lotti forniva un'analisi dettagliata della resa dei lotti e delle scadenze prefissate. La sezione sulla produzione includeva grafici sui trend degli scarti e della produzione, nonché tabelle dettagliate e card descrittive. Infine, le dashboard delle materie prime e delle macchine fornivano una visione completa della situazione delle materie

prime e delle performance delle macchine, permettendo di identificare rapidamente eventuali problemi e aree di miglioramento.

Machine Learning

Descrizione del Modello

Sfruttando il modulo time_series della libreria Pycaret, è stato sviluppato in ambiente Python un modello di forecasting in grado di prevedere le quantità di scarto generate nel processo produttivo. Il modello utilizzato è basato sull'algoritmo AutoETS (Automatic Error, Trend, Seasonality): una tecnica di modellizzazione che combina automaticamente componenti di errore, trend e stagionalità per effettuare previsioni su serie storiche.

Analisi delle Prestazioni

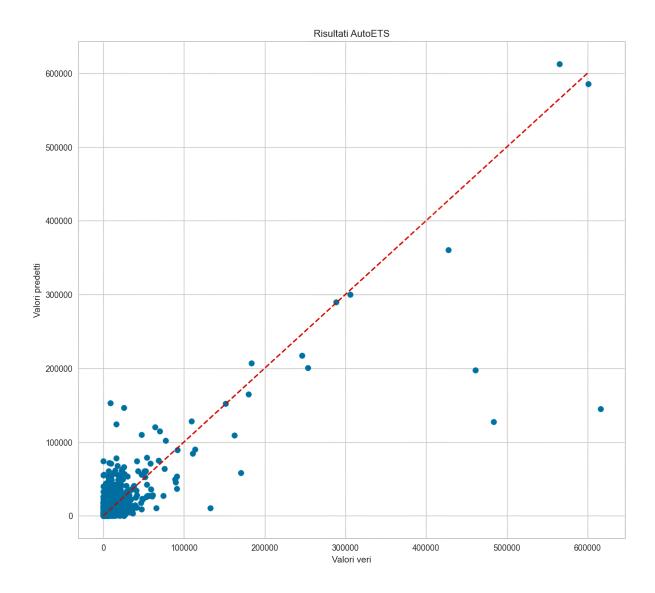
Per valutare la performance del modello, sono state utilizzate diverse metriche comunemente impiegate nel campo delle previsioni delle serie temporali. I risultati ottenuti sono riportati di seguito:

- MASE (Mean Absolute Scaled Error): 0.0577
- MAE (Mean Absolute Error): 1019.3907
- MAPE (Mean Absolute Percentage Error): 0.2919
- R2 (*R-squared*): 0.68

Questi risultati indicano che il modello ha una buona capacità predittiva, con errori assoluti e percentuali relativamente bassi e un coefficiente di determinazione (R2) che suggerisce una buona spiegazione della variabilità dei dati.

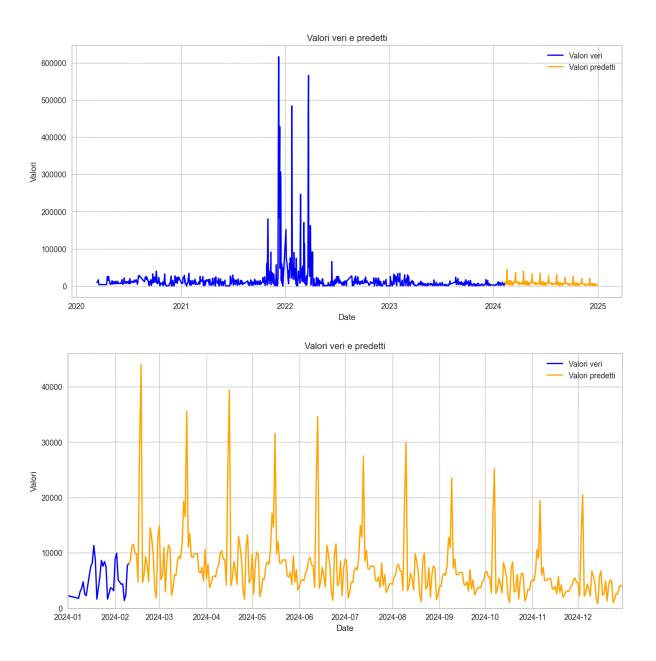
I seguenti grafici mostrano le prestazioni del modello confrontando i valori veri con quelli predetti.

1. Grafico di dispersione dei valori veri e predetti



Questo grafico mostra la relazione tra i valori predetti e quelli effettivi. La linea rossa tratteggiata rappresenta la linea di perfetta predizione (y=x). Come si può notare, la maggior parte dei punti si trova vicino a questa linea, indicando una buona precisione del modello.

2. Confronto tra i valori veri e predetti nel tempo



Questo grafico rappresenta l'andamento dei valori veri (in blu) e dei valori predetti (in arancione) nel tempo. È possibile osservare come il modello segua l'andamento dei dati storici, evidenziando la capacità di catturare picchi e variazioni stagionali.

Questi risultati dimostrano che il modello di forecasting sviluppato è efficace e fornisce previsioni accurate delle quantità di scarto nel processo produttivo, contribuendo così a una migliore gestione delle risorse e alla riduzione degli sprechi.

Conclusioni

Dopo aver esaminato i dati raccolti e aver applicato vari metodi analitici, siamo giunti a una serie di conclusioni chiave che possono guidare decisioni future e fornire raccomandazioni strategiche. Le conclusioni qui riportate sono il risultato di un'analisi rigorosa e sono supportate dai risultati ottenuti durante il processo analitico.

- 1. Il trend delle fermate è in aumento, ma sono sempre più brevi
- 2. Il trend del numero di lotti lavorati è positivo
- 3. Sono più i lotti in ritardo che quelli in orario
- Le macchine RAL01, RAL02 E RAL03 sono responsabili della maggior parte degli scarti e registrano i più alti valori di resa produttiva
- 5. Ogni quantità prodotta abbiamo in media 0.3 scarti
- 6. L'aumento della produzione, con picchi a fine 2023, è dovuto a lotti che trattano articoli semilavorati (che devono essere soggetti a ulteriori lavorazioni prima di poter essere venduti)
- 7. Lo scarto di materia prima è minimo

Il progetto ha raggiunto il suo obiettivo e ha gettato le basi per future esplorazioni e applicazioni. Il team di analisti dati di Tesar è fiducioso che le conclusioni derivate dall'analisi siano e saranno preziose per Wonder.

UML

Modello Socio-Tecnico

STRUTTURA / RISORSE Macchina Virtuale SOL Database On premise	 TECNOLOGIE SQL Server Management Studio
 SQL Database On-premise Script Python GitHub Repository Power BI Report 	 Visual Studio GitHub Google Documents Power BI Microsoft Teams
PERSONE	PROCESSI
Ferrari FedericoPalladino Mirko	Data LoadingData CleaningData Warehousing